

# Metaoptymalizacja algorytmów wielopopulacyjnych

Autor:

Filip Katulski

## Etap 1: State of the Art - obecny stan wiedzy

Poniższe artykuły i prace stanowiły źródło informacji dla tego projektu i używane w nich definicje i pojęcia służą za źródło informacji.

1. *What Can We Learn from Multi-Objective Meta-Optimization of Evolutionary Algorithms in Continuous Domains?* - Roberto Ugolotti, Laura Sani and Stefano Cagnoni

Wnioski:

- Algorytmy Ewolucyjne (EA) w swoich podstawowych ustawieniach mogą znajdować optima lokalne, jednak dopiero tuning parametrów może przybliżyć je do optimum globalnego.
- W artykule poruszono zagadnienia odnośnie dobierania parametrów Algorytmów Ewolucyjnych takie jak: natura problemu, jego ograniczenia, czas obliczeniowy.
- Użyty framework: EMOPaT - *Evolutionary Multi-Objective Parameter Tuning*.
- W pracy przedstawiono kilka wersji problemu badawczego w następujących wariantach:
  - Multi-Objective Single-Function Optimization Under Different Constraints - optymalizacja pojedynczej funkcji w ramach różnych warunków ograniczających
  - Multi-Function Optimization - wszystkie funkcje opisane w problemie badawczym są optymalizowane razem.

## 2. *Meta-optimization of multi-objective population-based algorithms using multi-objective performance metrics* - Krystian Łapa

Wnioski:

- W niniejszym artykule wybrano algorytm genetyczny (GA) do optymalizacji parametrów rozważanego algorytmu wielokryterialnego (metaoptymalizacja)
- Algorytmy populacyjne (population-based algorithms) to algorytmy oparte o populację rozwiązań, zwanych indywiduami (individuals). Mogą (lecz nie muszą) być oparte o działanie populacji prawdziwych, występujących w naturze i środowisku ludzkim.
- Artykuł opisuje nową metodę optymalizacji parametrów algorytmów populacyjnych. W zaproponowanej metodzie parametry algorytmu są wyznaczane przez funkcje zmieniające się od iteracji (iteration-dependent function). Funkcje te zwracają różne wartości parametrów w zależności od iteracji algorytmu i mogą mieć inny kształt zdefiniowany przez ich parametry.
- Optymalizować należy nie tylko parametry całkowite (np. liczba osobników w populacji), ale także parametry wartości rzeczywistej (np. parametry operatorów).

## 3. *Meta-optimization of massively concurrent optimization algorithms using Elixir technology* - Grzegorz Wcisło, praca dyplomowa

Wnioski:

- Metaoptymalizacja to proces wykorzystywania algorytmu optymalizacji do dostrojenia parametrów innego algorytmu optymalizacji.
- Istniejące metody metaoptymalizacji, np.: CALIBRA\*, CMA-ES, BOBYQA, MADS, ParamILS, Irace.
- MEOW jako workbench do uruchamiania algorytmów genetycznych, napisany w Elixirze, LEAP oraz DEAP napisane w Pythonie oraz EASEA napisany w C++ mogą posłużyć do uruchamiania algorytmów genetycznych, których parametry mają być docelowo zoptymalizowane.

4. *A Platform for Testing Multi-Population Evolutionary Algorithms using The BEAM Virtual Machine* - Jonatan Kłosko, Mateusz Benecki

Wnioski:

- Większość frameworków łączy to, że operacje ewolucyjne są stosowane oddzielnie do każdej osoby lub małej grupy osób. Takie podejście ma istotne ograniczenie - uniemożliwia zastosowanie bardziej wydajnej reprezentacji populacji i zastosowanie operacji na populacji w jednym kroku.
- Meow jest deklaratywny - algorytm można opisać w formie serii operacji jaką przechodzi populacja - pipeline.
- Meow może być uruchamiany przy pomocy CPU, GPU, Klastrze

Plan działania w ramach następnego etapu

1. Podstawy Elixir wraz z modułem Nx
2. Nauka obsługi iRace, Meow, LEAP, DEAP
3. Poszukiwanie dodatkowych frameworków optymalizacyjnych możliwych do nauczenia i wykorzystania w optymalnym czasie
4. Kontakt z twórcami pracy dyplomowej nt. Meow w kwestiach poprawnej konfiguracji Meow w ograniczonych warunkach
5. Kontakt z Grzegorzem Wcisło w sprawie możliwych opcji dodatkowych testów i wartych rozważenia problemów